



PUC-RIO

INF1036 - Probabilidade Computacional

Material 1 - Introdução

*Material Adaptado de Professor Hélio Lopes / Ana Carolina Letichevsky

A **Teoria das Probabilidades** é uma área da matemática que desenvolve **modelos** que podem ser utilizados para estudar **fenômenos aleatórios** ou **experimentos aleatórios**.

No contexto da **Teoria das Probabilidades** os **processos de observação** são chamados de **experimentos**.

Experimentos aleatórios são aqueles que, repetidos sobre as mesmas condições produzem **geralmente resultados diferentes**. Isso ocorre devido à **natureza imprevisível** dos fatores envolvidos.

Em contraponto, um **experimento é determinístico**, quando **repetido em condições semelhantes**, produzem **resultados exatamente iguais**. Não há incerteza.

Evento é um **resultado específico** ou **conjunto de resultados** de um **experimento aleatório** que nos interessa estudar ou observar.

O **modelo matemático** utilizado para estudar um determinado **fenômeno aleatório** varia em sua **complexidade** de acordo com o **fenômeno em questão**.

A **probabilidade de um evento** é a **medida** ou **chance** desse evento **ocorrer**.

Definição **clássica de probabilidade** (também chamada definição de Laplace). Sejam:

- **S** : o conjunto de todos os **possíveis resultados** (saídas) de um experimento, chamado **espaço amostral**;
- **ζ_i** : um elemento qualquer de **S** , chamado de **evento elementar** ou **ponto amostral**;
- **$E \subseteq S$** : um **subconjunto** do espaço amostral **S** , formado por **eventos elementares favoráveis** à ocorrência de um determinado evento **E** , chamado simplesmente de **evento**.

A **probabilidade do evento E** ocorrer, ou simplesmente a probabilidade do evento **E** , é definida como a razão entre o **número de elementos** de **E** e o **número de elementos** de **S** .

$$P(E) = \frac{\text{número de elementos de } E}{\text{número de elementos de } S}$$

Na definição de probabilidade de Laplace é preciso considerar que:

- Há um número finito (**n**) de elementos em **S** ;
- A união de todos os eventos é **S** ;
- Os eventos elementares (pontos amostrais) de **S** são **equiprováveis** (todos são igualmente prováveis);
- Todo evento **E** é obtido a partir da união de **m** pontos do espaço amostral sendo **$m \leq n$**

$$P(E) = \frac{\text{número de casos favoráveis}}{\text{número de casos possíveis}} = \frac{n(E)}{n(S)} = \frac{m}{n}$$

portanto, para todo evento **E** , **$0 \leq P(E) \leq 1$** .

Experimento – Lançar uma moeda duas vezes



Considere o experimento aleatório “**Lançar uma moeda não viciada duas vezes e observar os resultados.**”. Os possíveis resultados são as combinações entre **Cara** e **Coroa**.

O **espaço amostral**, S , é o **conjunto de todos os resultados possíveis** de um experimento aleatório, logo:

$$S = \{(Cara, Cara), (Cara, Coroa), (Coroa, Cara), (Coroa, Coroa)\}$$

Cada **par** representa um **resultado possível**.

Espaço amostral S

(Cara, Coroa)

(Cara, Cara)

(Coroa, Coroa)

(Coroa, Cara)

Alguns possíveis **eventos** (conjuntos de resultados com alguma característica).

A = “**Nos dois lançamentos a moeda mostrar o mesmo lado.**”

$$A = \{(Cara, Cara), (Coroa, Coroa)\}$$


B = “**Em pelo menos um lançamento a moeda mostrou Cara.**”

$$B = \{(Cara, Cara), (Cara, Coroa), (Coroa, Cara)\}$$

Variáveis aleatórias

Uma **variável aleatória** (v.a.) é uma função que associa **cada resultado possível** de um **experimento aleatório** a um **número real**. Ela é usada em probabilidade e estatística para **quantificar incertezas**.

Considere o experimento aleatório “**Lançar uma moeda não viciada duas vezes e observar os resultados.**” e a variável aleatória X = “**Número de caras que ocorre no experimento aleatório.**”.




Variáveis aleatórias

Dado um experimento aleatório, descrito pelo espaço de probabilidades, uma função numérica X :

$X : S \rightarrow R$, onde S é o conjunto de resultados possíveis.

É uma **variável aleatória** do experimento. Após a execução do experimento, obtém-se um **valor numérico específico** da variável aleatória X , denominado **realização**.

Nos interessa estudar as **distribuições de probabilidade** das **variáveis aleatórias**.



Processos Estocástico

Um **Processo Estocástico** é um **modelo matemático** utilizado para o **estudo de fenômenos aleatórios** que tem como resultados **funções**.

No contexto da **Teoria das Probabilidades**, um **Processo Estocástico** é uma **família de variáveis aleatórias** representando a **evolução de um sistema** de valores, em geral, com o **tempo**, mas pode ser a uma **distância a um ponto fixo**, um **volume**, etc.

Ao invés de um processo que possui um único modo de evoluir, em um **Processo Estocástico**, há uma **indeterminação**. Assim, mesmo que se conheça a **condição inicial**, existem **diferentes direções** nas quais o processo **pode evoluir**.



Agora vamos repetir o experimento aleatório várias vezes no tempo.

Por exemplo, vamos lançar a moeda duas vezes por minuto, e em cada instante t medir $X(t) =$ “Número de caras que ocorre no experimento aleatório naquele minuto.”.

Assim, definimos um **processo estocástico** discreto no tempo:


$$\{X(t)\}_{t \in \mathbb{N}}$$

Sendo cada $X(t)$ uma **variável aleatória** com os possíveis valores $\{0, 1, 2\}$, e a **mesma distribuição**.

A sequência abaixo, supondo cinco minutos:

$$X(1) = 1, X(2) = 1, X(3) = 0, X(4) = 0, X(5) = 1$$


é uma **realização do processo estocástico**.



Processo Estocástico

Se o processo for repetido, **outra realização** (com outra ou mesma sequência de valores) pode ser obtida.

A **realização** pode ser vista como uma **função** que associa cada tempo t ao valor observado $X(t)$.



O processo estocástico é definido por uma sequência infinita de variáveis aleatórias $X(t)$:

$$\{X(t)\}_{t \in N}$$

Onde:

- $t = 1, 2, 3, \dots$ representa o número da repetição do experimento (tempo discreto).
- $X(t)$ é o número de caras que ocorre no experimento aleatório em t .
- Cada $X(t)$ assume valores em $\{0, 1, 2\}$, com probabilidades $\{0.25, 0.5, 0.25\}$.
- Os $X(t)$'s são independentes entre si.

Um modelo matemático que gera o preço de uma ação pode ser dado por:

$$S(t) = S_0 e^{\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W(t)}$$

Onde:

- S_0 é o preço inicial da ação.
- μ é o retorno médio esperado.
- σ é uma volatilidade.
- $W(t)$ é uma aleatoriedade (ruído branco).
- $S(t)$ é uma variável aleatória que representa o preço da ação em t .

Aplicações:

- Economia
- Atuária
- Engenharia
- Saúde
- Física
- Topografia
- Jogos
- Aprendizado de Máquinas

Uma **Simulação Estocástica** imita o comportamento de um determinado sistema buscando obter diferentes cenários das saídas desses sistemas.

Em uma **Simulação Estocástica** uma dada variável aleatória (ou família de variáveis aleatórias), cujo comportamento é representado matematicamente, pode ser **reproduzida numericamente** de modo que cada simulação tenha um resultado diferente.

Os **métodos de Simulação Estocástica** são procedimentos que **envolvem a geração de números pseudoaleatórios**.

Simular um **grande número de cenários** permite **aproximar com precisão a distribuição de probabilidade** de todas as saídas e essa precisão aumenta à medida que o número de cenários aumentam.

Simular o processo significa **gerar artificialmente amostras** (realizações) do processo usando um **gerador de números pseudoaleatórios** (computacionalmente).

No nosso exemplo da moeda, na prática, o computador é utilizado para "sortear" cara ou coroa para cada lançamento da moeda em um dado instante t , e a seguir computar o número de caras $X(t)$.

Para $t = 1$ até 10 , podemos simular:

$$X(1) = 1, X(2) = 2, X(3) = 1, X(4) = 0, \dots$$

Essa é uma **realização do processo**.

Os métodos de Simulação Monte Carlo (SMC) utilizam geradores de números pseudoaleatórios para simular possíveis valores da variável de interesse e assim obter a estimativa para o valor verdadeiro da mesma.

O nome “Monte Carlo” é uma referência ao famoso Cassino de Mônaco. A aleatoriedade e a repetição são as principais características dos métodos de Monte Carlo, que são análogas às atividades praticadas em um cassino.

Os métodos de SMC são úteis para estudar:

- Sistemas não determinísticos.
- Sistemas determinísticos muito complexos para se modelar analiticamente.
- Sistemas determinísticos com alta dimensionalidade.

Principais requisitos para os métodos de SMC:

- Possuir o conhecimento das distribuições de probabilidade das variáveis de entrada.
- Possuir um gerador de números pseudoaleatórios para criar cenários das variáveis de entrada no sistema.

Qual a probabilidade de que $X(t) = 2$ (duas caras)?

Pode ser obtida diretamente da distribuição de probabilidade $P(X(t) = 2) = 1/4$.

Mas com a Simulação de Monte Carlo, podemos simular várias vezes e contar a frequência com que $X(t) = 2$, ou seja:

- Simule $X(t)$ para $t = 1, \dots, 10000$.
- Conte quantas vezes $X(t) = 2$.
- Estime:

$$P(X(t) = 2) = \frac{\text{número de vezes que } X(t)=2}{10000}$$

Geração de Números Pseudoaleatórios



Números aleatórios:

- São gerados por um processo físico;
- Uma sequência de números é aleatória quando a sua menor representação é ela mesma.

Números pseudoaleatórios:

- Podem ser gerados em computadores digitais a partir de funções que não são efetivamente aleatórias;
- Os geradores de números pseudoaleatórios (PRNGs — *Pseudo-Random Number Generators*) produzem uma sequência determinística de números na precisão do computador, que imita uma sequência de variáveis aleatórias independentes e uniformemente distribuídas entre 0 e 1;
- Uma sequência de números pseudoaleatórios é imprevisível na medida que ao ver a sequência não é possível explicitar a regra determinística que a produz.
- Bons geradores terão propriedades interessantes para aplicações Estatísticas.

Propriedades desejáveis de um bom gerador de números pseudoaleatórios:

- Possuir um padrão aleatório: ele deve passar em testes estatísticos de aleatoriedade;
- Possuir um período longo: passar por um grande número de estados antes de voltar a um estado já produzido;
- Ser eficiente: ele deve ser executado rapidamente e requerer um baixo armazenamento;
- Ser de fácil reprodução: a partir de determinadas condições iniciais ele deve produzir sempre a mesma sequência;
- Ser portátil: a partir de determinadas condições iniciais a sequência gerada deve ser a mesma em qualquer computador.

Python e R


Apesar de existirem outras possibilidades, estas duas linguagens tem polarizado as discussões sobre qual ferramenta utilizar para análise de dados.

As duas linguagens são gratuitas, podem ser instaladas em diversos sistemas operacionais, possuem grande comunidade, muita documentação e ambas possuem vantagens e desvantagens, pontos fortes e pontos fracos.

As duas linguagens podem ser utilizadas em conjunto, ou instalando um pacote no R, para chamada de scripts Python ou instalando um pacote no Python, para executar funções e comandos R.

Ambiente de desenvolvimento

<https://www.anaconda.com/products/individual> (distribuição open source)



Instalação padrão

- Spyder 4.1.5
- Python 3.8.5

Após a instalação do Anaconda, deve ser realizada a instalação do RStudio através do próprio ambiente Anaconda.

- RStudio 1.1.456
- R 3.6.1

Introdução ao Ambiente R



O R (<http://www.r-project.org/>) é ao mesmo tempo uma linguagem de programação e um ambiente para cálculos estatísticos e gráficos.

Foi criada por Ross Ihaka e Robert Gentleman na Universidade de Auckland, Nova Zelândia, e atualmente é desenvolvido pela equipe de Desenvolvimento do R.

É uma linguagem especializada em computação de dados, sendo gratuita e estando disponível em vários sistemas operacionais.

É uma linguagem interpretada, tipicamente utilizada através de um interpretador de comandos.

É também altamente expansível com o uso dos pacotes, que são bibliotecas para sub-rotinas específicas ou áreas de estudo específicas.

Pode ser aplicada nas mais diversas áreas e para os mais diversos fins, tais como: pesquisa científica, business analytics, desenvolvimento de software, relatórios estatísticos, econometria e análise financeira, ciência sociais e big data analytics.

RStudio



The screenshot displays the RStudio integrated development environment (IDE) with the following components:

- Source Editor:** A single file named 'Untitled1' is open, showing a single line of code: `1`. The editor includes a toolbar with icons for saving, running, and other actions.
- Environment Pane:** Located on the right, it shows the 'Global Environment' which is currently empty, with the message 'Environment is empty'.
- File Explorer:** Also on the right, it shows a list of files and folders. A context menu is open over the 'Ho' folder, with the option 'Create a new folder' highlighted. The file list includes folders like 'Graphics', 'IISExpress', and 'Integration Services Script Component', as well as files like 'script.sql'.
- Console:** At the bottom left, it displays the R startup message, including the copyright notice for 2018 and instructions on how to use R, such as `license()`, `contributors()`, and `demo()`.

Para conseguir ajuda sobre um comando, pode ser usada a função help:

```
help(comando) ou ?comando
```

Para instalar um pacote no seu ambiente, você pode usar o comando `install.packages()` com o nome do pacote entre parênteses "":

```
install.packages("nomepacote")
```

Para usar o pacote em seu programa, use o comando `library()` com o nome do pacote como parâmetro (sem ""):

```
library(nomepacote)
```


Algumas características do R



- R é **case-sensitive**: então “A” e “a” são símbolos diferentes e se referem a diferentes variáveis.
- Comandos diferentes são separados por ponto e vírgula “;”.
- Todos os símbolos alfanuméricos são permitidos, incluindo “.” e “_”.
- Comentários começam com “#”.
- Como a maioria das linguagens de programação, R permite atribuir valores a variáveis.

```
> # Comentário
> A = 2; a = "uva";
> print(A);
[1] 2
> print(a);
[1] "uva"
> .C=3;
> print(.C+2);
[1] 5
>
```

Constantes armazenadas no R

```
> pi
[1] 3.141593
>
> letters
[1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q"
   "r" "s" "t" "u" "v" "w" "x" "y" "z"
>
> LETTERS
[1] "A" "B" "C" "D" "E" "F" "G" "H" "I" "J" "K" "L" "M" "N" "O" "P" "Q"
   "R" "S" "T" "U" "V" "W" "X" "Y" "Z"
>
> month.abb
[1] "Jan" "Feb" "Mar" "Apr" "May" "Jun" "Jul" "Aug" "Sep" "Oct" "Nov" "
Dec"
>
> month.name
[1] "January"    "February"   "March"      "April"      "May"        "June"
     "July"      "August"    "September"
[10] "October"    "November"  "December"
```

Tipos de dados no R



- character (“aula”)
- numeric (1.)
- integer (3)
- logical (TRUE or FALSE)
- vector (tipos homogêneos)
- list (parecidos com vectors, mas heterogêneos)
- matrix
- missing values (NA)
- ...

Operadores Matemáticos

A lista abaixo apresenta alguns dos principais operadores matemáticos do R.

Operador	Descrição
<code>+</code>	Operador de adição
<code>-</code>	Operador de subtração
<code>*</code>	Operador de multiplicação
<code>/</code>	Operador de divisão
<code>:</code>	Operador de sequência
<code>^</code>	Operador exponencial
<code>%%</code>	Operador de módulo

Operadores Lógicos

São operados binários para realização de testes entre duas variáveis (objetos). Estas operações retornam o valor TRUE (1) ou FALSE (0).

Operador	Descrição
==	Operador de igualdade
>	Operador “maior que”
<	Operador “menor que”
<=	Operador “menor ou igual”
!	Operador “Não”
&	Operador lógico “E”
	Operador lógico “OU”

- Introdução à Probabilidade.
- Algoritmos para geração de números pseudoaleatórios.
- Algoritmos para simulação estocástica de variáveis aleatórias discretas e aplicações.
- Algoritmos para simulação estocástica de variáveis aleatórias contínuas e aplicações.
- Algoritmos para simulação de eventos discretos: filas, redes, etc.

1. Sheldon Ross, Simulation, Academic Press. 5th Edition, 2012.
2. Jane Horgan, Probability with R: An Introduction with Computer Science Applications, Willey, 2009.
3. Douglas C. Montgomery, George C. Runger. Estatística Aplicada e Probabilidade Para Engenheiros, LTC, 2016.

1. Donald E. Knuth, Art of Computer Programming, Volume 2: Seminumerical Algorithms, Addison-Wesley Professional, 1997.
2. W. Celes, R. Cerqueira, J.L. Rangel. Introdução à estruturas de dados com técnicas de programação em C. Elsevier, 2016.
3. A. Downey. Pense em Python. Novatec, 2016.
4. I. Malta, S. Pesco, H. Lopes. Cálculo a uma Variável, Volume I. Edição Loyola, Editora PUCRio, 2002.
5. I. Malta, S. Pesco, H. Lopes. Cálculo a uma Variável, Volume II. Edição Loyola, Editora PUCRio, 2002.